



Статистические методы в инженерных исследованиях

Лабораторная работа 4

Обработка результатов пассивного эксперимента.

Корреляционный анализ

Цель лабораторной работы: Получить умения и отработать навыки методов корреляционного анализа.

Задачи лабораторной работы:

1. Провести пассивные эксперименты.
2. Обработать результаты пассивных экспериментов.
3. Оформить отчет по лабораторной работе.

Метод вычисления коэффициента корреляции зависит от вида шкалы, к которой относятся переменные.

Типы шкал		Показатель
Переменная X	Переменная Y	
Интервальная или отношений	Интервальная или отношений	Коэффициент корреляции Пирсона
Ранговая, интервальная или отношений	Ранговая, интервальная или отношений	Коэффициент корреляции рангов Спирмена
Ранговая	Ранговая	Коэффициент корреляции Кендалла
Дихотомическая	Дихотомическая	Коэффициент ассоциации
Дихотомическая	Ранговая	Рангово-бисериальный коэффициент корреляции
Дихотомическая	Интервальная или отношений	Бисериальный коэффициент корреляции
Интервальная	Ранговая	Не разработан

Часто возникает потребность анализа связи между переменными, которые не могут быть измерены в интервальной или реляционных шкалах, но тем не менее поддаются упорядочению и могут быть проранжированы по степени убывания или возрастания признака. Для определения тесноты связи между признаками, измеренными в **порядковых шкалах**, применяются методы **ранговой корреляции**.

Бисериальная корреляция является методом корреляционного анализа между двумя переменными, одна из которых измерена в **дихотомической шкале**.

Коэффициент ранговой корреляции Спирмена

Каждая из двух совокупностей располагается в виде вариационного ряда с присвоением каждому члену ряда соответствующего порядкового номера (**ранга**), выраженного натуральным числом. Одинаковым значениям ряда присваивают **среднее ранговое число**.

Сравниваемые признаки можно ранжировать в любом направлении: как в сторону ухудшения качества, так и наоборот. Главное, чтобы обе переменные были проранжированы **одинаковым способом**.

Коэффициент ранговой корреляции Спирмена $-1 \leq r_s \leq 1$ и находится по формуле:

$$r_s = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n^3 - n}$$

где $d_i = rang(x_i) - rang(y_i) = R_x - R_y$ – разность рангов для каждой i пары из n наблюдений.

Если в вариационных рядах для X и Y встречаются члены ряда с одинаковыми ранговыми числами, то в формулу необходимо внести поправки T_x и T_y на одинаковые ранги:

$$r_s = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n^3 - n - \frac{1}{2}(T_x + T_y)}; T = \sum_{k=1}^l (t_k^3 - t_k)$$

где l – число групп в вариационном ряду с одинаковыми ранговыми числами;
 t_k – число членов в каждой из l групп.

Коэффициент ранговой корреляции Спирмена

Проверка гипотезы об отсутствии связи

Постановка задачи:

Нулевая гипотеза $H_0: r_S = 0$ (коэффициент ранговой корреляции Спирмена значимо не отличается от нуля)

Альтернативная гипотеза $\bar{H}: r_S \neq 0$ (коэффициент ранговой корреляции Спирмена значимо отличается от нуля)

Проверка значимости коэффициента ранговой корреляции Спирмена производится:

- 1) путем сравнения вычисленного коэффициента r_S с критическими значениями коэффициента ранговой корреляции Спирмена $r_{\alpha,n}$, взятым из статистических таблиц для выбранного уровня значимости α и числа пар наблюдений n (при $n < 30$):

$$|r_S| < r_{\text{табл}} = r_{\alpha,n}$$

- 2) по критерию Стьюдента (при $n \geq 30$):

$$t_{\text{расч}} = |r_S| \sqrt{\frac{n-2}{1-r_S^2}} < t_{\text{табл}} = t_{\alpha;v=n-2}$$

Пример 1.

На основании данных ФСТЭК РФ (<https://bdu.fstec.ru/>) требуется оценить корреляционную связь между количеством уязвимостей в ПО различных производителей и количеством уязвимостей ПО различных производителей, связанных с инцидентами информационной безопасности за период 1-го полугодия 2025 года при уровне значимости $\alpha = 0,05$.

Производитель ПО	Количество уязвимостей	Количество уязвимостей, связанных с инцидентами
Сообщество свободного программного обеспечения	1574	3
ООО "РусБИТех-Астра"	1077	5
АО "НППКТ"	886	5
ООО "РЕД СОФТ"	676	7
Microsoft	612	33
Red Hat Inc.	536	2
Adobe Systems Inc.	442	0
АО "ИБК"	362	1
Novell Inc.	325	2
Canonical Inc.	308	1

Производитель ПО	X -количество уязвимостей	Y -количество уязвимостей, связанных с инцидентами	R_x - ранг (количество уязвимостей)	R_y -ранг (количество уязвимостей, связанных с инцидентами)	d_i	d_i^2
Сообщество свободного программного обеспечения	1574	3	1,0	5,0	-4,0	16,00
ООО "РусБИТех-Астра"	1077	5	2,0	3,5	-1,5	2,25
АО "НППКТ"	886	5	3,0	3,5	-0,5	0,25
ООО "РЕД СОФТ"	676	7	4,0	2,0	2,0	4,00
Microsoft	612	33	5,0	1,0	4,0	16,00
Red Hat Inc.	536	2	6,0	6,5	-0,5	0,25
Adobe Sistems Inc.	442	0	7,0	10,0	-3,0	9,00
АО "ИВК"	362	1	8,0	8,5	-0,5	0,25
Novell Inc.	325	2	9,0	6,5	2,5	6,25
Canonical Inc.	308	1	10,0	8,5	1,5	2,25
			$\sum R = 55,0$	$\sum R = 55,0$	$\sum d_i = 0$	$\sum d_i^2 = 56,50$
	$r_{xy} = 0,05$ $t_{расч} = 0,14; t_{0,05;8} = 2,31$				$r_s = 0,62$ $r_{0,05;10} = 0,64$	

Коэффициент ранговой корреляции Кендалла

Производится ранжирование рядов переменных, при этом одинаковым значениям ряда присваивают среднее ранговое число. Первая переменная должна быть упорядочена по возрастанию рангов. .

Коэффициент ранговой корреляции Кендалла $-1 \leq \tau \leq 1$ и находится по формуле:

$$\tau = \frac{4 \sum_{i=1}^n R_i}{n(n-1)} - 1$$

где n – объем выборки (число сопоставляемых пар);

R_i – число рангов во втором вариационном ряду, больших, чем данное ранговое число и расположенных ниже него.

Проверка гипотезы об отсутствии связи

Постановка задачи:

Нулевая гипотеза $H_0: \tau = 0$ (коэффициент ранговой корреляции Кендалла значимо не отличается от нуля)

Альтернативная гипотеза $\bar{H}: \tau \neq 0$ (коэффициент ранговой корреляции Кендалла значимо отличается от нуля)

Проверка значимости коэффициента ранговой корреляции Кендалла заключается в сопоставлении вычисленного значения коэффициента τ по модулю с критическим значением $\tau_{\alpha,n}$:

$$|\tau| < \tau_{\alpha,n} = z_{1-\alpha/2} \sqrt{\frac{2(2n+5)}{9n(n+1)}}$$

где n – объем выборки, $z_{1-\alpha/2}$ – квантиль нормированного нормального распределения.

Пример 2.

На основании данных ФСТЭК РФ (<https://bdu.fstec.ru/>) требуется оценить корреляционную связь между количеством уязвимостей в ПО различных производителей и количеством уязвимостей ПО различных производителей, связанных с инцидентами информационной безопасности за период 1-го полугодия 2025 года при уровне значимости $\alpha = 0,05$.

Производитель ПО	Количество уязвимостей	Количество уязвимостей, связанных с инцидентами
Сообщество свободного программного обеспечения	1574	3
ООО "РусБИТех-Астра"	1077	5
АО "НППКТ"	886	5
ООО "РЕД СОФТ"	676	7
Microsoft	612	33
Red Hat Inc.	536	2
Adobe Systems Inc.	442	0
АО "ИБК"	362	1
Novell Inc.	325	2
Canonical Inc.	308	1

Производитель ПО	X -количество уязвимостей	Y -количество уязвимостей, связанных с инцидентами	R_x - ранг (количество уязвимостей)	R_y -ранг (количество уязвимостей, связанных с инцидентами)	R_i
Сообщество свободного программного обеспечения	1574	3	1,0	5,0	5
ООО "РусБИТех- Астра"	1077	5	2,0	3,5	5
АО "НППКТ"	886	5	3,0	3,5	5
ООО "РЕД СОФТ"	676	7	4,0	2,0	5
Microsoft	612	33	5,0	1,0	5
Red Hat Inc.	536	2	6,0	6,5	3
Adobe Systems Inc.	442	0	7,0	10,0	0
АО "ИВК"	362	1	8,0	8,5	0
Novell Inc.	325	2	9,0	6,5	1
Canonical Inc.	308	1	10,0	8,5	0
					$\sum R_i = 29$
					$\tau = 0,29$
					$\tau_{\alpha n} = 0,44$

Коэффициент конкордации (согласованности) Кендалла

Коэффициент конкордации Кендалла используется в случае, когда совокупность объектов характеризуется несколькими последовательностями рангов, а исследователю необходимо установить статистическую связь между этими последовательностями.

Такие задачи возникают, например, при анализе экспертных оценок: несколько экспертов ранжируют одних и тех же испытуемых по определенному качеству, а для проведения углубленного анализа ситуации и принятия обоснованного решения требуется определить степень согласованности мнений группы экспертов.

Коэффициент конкордации Кендалла $0 \leq W \leq 1$ и находится по формуле:

$$W = \frac{12 \sum_{i=1}^n D_i^2}{m^2(n^3 - n)}$$

где n – число оцениваемых объектов (испытуемых);

m – число ранговых последовательностей (количество экспертов);

$D_i = d_i - \bar{d}$ – отклонение суммы рангов i объекта от средней суммы рангов всех объектов

$$d_i = \sum_{j=1}^m R_{ij} ; \bar{d} = \frac{\sum_{i=1}^n d_i}{n}$$

Средняя сумма рангов всех объектов $\bar{d}$ может быть вычислена по формуле: $\bar{d} = \frac{1}{2}m(n + 1)$ (для контроля).

Коэффициент конкордации (согласованности) Кендалла

При наличии одинаковых рангов у одного эксперта коэффициент конкордации находится по формуле:

$$W = \frac{12 \sum_{i=1}^n D_i^2}{m^2(n^3 - n) - m \sum_{j=1}^m T_j}$$

$$T_j = \sum_{k=1}^l (t_k^3 - t_k)$$

t_k – число одинаковых значений в k группе (связке) для j эксперта;

l – число связок (групп с одинаковыми значениями) в ранговой последовательности j эксперта.

Проверка гипотезы об отсутствии связи

Постановка задачи:

Нулевая гипотеза H_0 : $W = 0$ (мнения экспертов не согласуются друг с другом)

Альтернативная гипотеза $\bar{H}$: $W \neq 0$ (мнения экспертов согласуются)

При относительно большом количестве объектов $n \geq 7$ проверка проводится с помощью критерия Пирсона.

Коэффициент конкордации значимо отличается от нуля, если:

$$\chi_{\text{расч}}^2 = m(n-1)W > \chi_{\text{табл}}^2 = \chi_{\alpha; v=n-1}^2$$

Значимость коэффициента конкордации при малом количестве объектов n проверить сложно.

Пример 3 – Задача 1.

На основании данных ФСТЭК РФ (<https://bdu.fstec.ru/>) требуется экспертным путем оценить уровень опасности уязвимости по типам ПО за период 1-го полугодия 2025 года при уровне значимости $\alpha = 0,05$.

Экспертная группа – не менее 3 экспертов.

Присвоение рангов:

Уровень опасности	Низкий	Средний	Высокий	Критический
Ранг	1	2	3	4

**Спасибо
за внимание!**

ITMO *re than a*
UNIVERSITY

Федоров Алексей Владимирович
avfedorov@itmo.ru