



Статистические методы в инженерных исследованиях

Лабораторная работа 5

Обработка результатов пассивного эксперимента.

Регрессионный анализ

Цель лабораторной работы: Получить умения и отработать навыки регрессионного анализа.

Задачи лабораторной работы:

1. Провести пассивные эксперименты.
2. Обработать результаты пассивных экспериментов.
3. Оформить отчет по лабораторной работе.

При изучении статистической зависимости обычно ограничиваются исследованием усредненной зависимости (Как в среднем будет изменяться значение одной величины при изменении другой?). Такая зависимость называется **регрессионной**.

Более строго, **регрессионная зависимость между двумя случайными величинами** — это функциональная зависимость между значениями одной из них и условным математическим ожиданием другой.

На практике по экспериментальным данным можно найти только оценку (приближенное выражение) функции регрессии, т.е. по выборке определяют **выборочное (эмпирическое) уравнение регрессии**.

Как правило, до проведения эксперимента выбирают вид выборочной функции регрессии с точностью до нескольких параметров, а значения параметров определяют по выборке.

Вид эмпирической функции регрессии определяют исходя из:

- 1) теоретических соображений о физической сущности исследуемой зависимости;
- 2) опыта предыдущих исследований;
- 3) характера расположения точек на **корреляционном поле**, которое получается, если отметить на плоскости все точки с координатами $(x_i; y_i)$, соответствующие наблюдениям.

Наибольший интерес представляет линейное эмпирическое уравнение регрессии, поскольку:

- 1) это наиболее простой случай для расчетов и анализа;
- 2) при нормальном распределении модельная функция регрессии является линейной.

Регрессионный анализ

При проведении регрессионного анализа принимаются следующие допущения:

- 1) входной параметр x измеряется с пренебрежимо малой ошибкой. Появление ошибки в определении y объясняется наличием в процессе не выявленных переменных и случайных воздействий, не вошедших в уравнение регрессии;
- 2) результаты наблюдений $y_1, y_2, \dots, y_n$ над выходной величиной представляют собой независимые нормально распределенные случайные величины;
- 3) при проведении эксперимента с объемом выборки n при условии, что каждый опыт повторен m раз, выборочные дисперсии $S_1^2, S_2^2, \dots, S_n^2$ должны быть однородны.

При выполнении измерений в различных условиях возникает задача сравнения точности измерений. При этом следует подчеркнуть, что экспериментальные данные можно сравнивать только тогда, когда их дисперсии однородны (принадлежность экспериментальных данных к одной и той же генеральной совокупности).

Однородность дисперсий свидетельствует о том, что среди сравниваемых дисперсий нет таких, которые с заданной надежностью превышали бы все остальные, т.е. была бы большая ошибка. При одинаковом числе параллельных опытов однородность дисперсии оценивается по критерию Кохрена, а для сравнения двух дисперсий целесообразно воспользоваться F-критерием Фишера.

После того как уравнение регрессии найдено, необходимо провести статистический анализ результатов, который состоит в следующем:

- 1) проверяется адекватность модели (уравнения регрессии).
- 2) проверяется значимость всех коэффициентов уравнения регрессии;

Пример 1.

Дано: Выборочные экспериментальные данные средних значений твердости H и предела прочности σ_B сталей различных марок, представлены в таблице 5.1.


Найти: регрессионную зависимость предела прочности σ_B от значений твердости H при уровне значимости $\alpha = 0,05$ и доверительной вероятности $p = 0,95$.

Таблица 5.1

n	1	2	3	4	5	6
H, HB	111	144	172	190	173	205
$\sigma_B, МПа$	447	452	532	571	589	634
n	7	8	9	10	11	12
H, HB	193	257	240	285	314	398
$\sigma_B, МПа$	675	744	815	894	976	1128

Решение:

r_{xy}	0,9797	=КОРРЕЛ(С3:Н3;С4:Н4)
$cov(x; y)$	16700,68	=КОВАРИАЦИЯ.В(С3:Н3;С4:Н4)
S_x	80,0	=СТАНДОТКЛОН.В(С3:Н3)
S_y	213,1	=СТАНДОТКЛОН.В(С4:Н4)




$$\bar{y} = b_0 + b_1 \bar{x} \quad \rightarrow \quad b_0 = \bar{y} - b_1 \bar{x} \quad b_1 = r_{xy} \frac{S_y}{S_x}$$

$r_{xy}(r_{H\sigma_B})$	0,9797
$S_x(S_H)$	80,0
$S_y(S_{\sigma_B})$	213,1
$\bar{x}(\bar{H})$	223,5
$\bar{y}(\bar{\sigma}_B)$	704,8



b_1	2,6098
b_0	121,4563



При моделировании приходится формализовать связи исследуемого явления (процесса), из-за чего возможна потеря некоторой информации об объекте. Иногда некоторые связи не учитываются. В то же время основное требование к математической модели заключается в ее пригодности для решения поставленной задачи и адекватности процессу.

Регрессионную модель называют **адекватной**, если предсказанные по ней значения y согласуются с результатами наблюдений.

В основе процедуры проверки адекватности модели лежат предположения, что случайные ошибки наблюдений являются независимыми, нормально распределенными случайными величинами с нулевыми средними значениями и одинаковыми дисперсиями.

1. Проверка гипотезы о адекватности модели (уравнения регрессии).

Постановка задачи:

Нулевая гипотеза H_0 : «Уравнение регрессии адекватно»

Альтернативная гипотеза $\bar{H}$: «Уравнение регрессии неадекватно»

Требуется проверить гипотезу H_0 при заданном уровне значимости α .

$$F_{\text{расч}} = \frac{S_y^2}{S_{\text{уост}}^2} > F_{\text{табл}} = F_{\alpha; v_1; v_2} \quad v_1 = n - 1; v_2 = n - l,$$

l - число членов аппроксимирующего полинома, $l = k + 1$ (k - число факторов)

$F_{\text{расч}}$ показывает, во сколько раз уравнение регрессии предсказывает результаты опытов лучше, чем $\bar{y} = \frac{\sum_{i=1}^n y_i}{n}$

$$S_y^2 = \frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n - 1} \quad S_{\text{уост}}^2 = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n - l}$$

$\hat{y}_i$ - значения параметра y , которое рассчитывается по уравнению регрессии при $x = x_i$.

$$F_{\text{расч}} = \frac{45415,11}{2012,36} = 22,57 > 2,94 = F_{\text{табл}} = F_{0,05;11;10}$$

Схема дисперсионного анализа:

Компоненты дисперсии	Сумма квадратов	Число степеней свободы	Дисперсия на одну степень свободы
Общая	$SS_{\text{tot}} = \sum_{i=1}^n (y_i - \bar{y})^2$	$n - 1$	$S_y^2 = \frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n - 1}$
Факторная	$SS_{\text{reg}} = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$	k	$S_{\hat{y}}^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{k}$
Остаточная	$SS_{\text{res}} = \sum_{i=1}^n (y_i - \hat{y}_i)^2$	$n - k - 1$	$S_{\text{уост}}^2 = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n - k - 1}$

$$F_{\text{расч}} = \frac{S_{\hat{y}}^2}{S_{\text{уост}}^2} > F_{\text{табл}} = F_{\alpha; v_1=k; v_2=n-k-1}$$

$$R^2 = \frac{SS_{\text{reg}}}{SS_{\text{tot}}} = \frac{479442,62}{499566,25} = 0,9597$$

$$F_{\text{расч}} = \frac{R^2(n-1)}{1-R^2} = 116,68 > 4,96 = F_{0,05, v_1=1, v_2=10}$$

В большинстве случаев при проведении экспериментальных исследований (проведении активного эксперимента) в каждой i – й точке x_i для повышения надежности и достоверности осуществляется не одно, а m параллельных измерений (примем для простоты, что m одинаково для каждого фактора). Тогда число экспериментальных значений величины y составит $N = n \times m$.

В этом случае оценка адекватности модели производится следующим образом:

- 1) определяется среднее из серии параллельных опытов при $x = x_i$: $\bar{y}_i = \frac{\sum_{j=1}^m y_{ij}}{m}$
- 2) проверяются однородности дисперсий: $S_i^2 = \frac{\sum_{j=1}^m (y_{ij} - \bar{y}_i)^2}{m-1}$ - выборочная дисперсия; $G_{\text{расч}} = \frac{S_{\text{max}}^2}{\sum_{i=1}^n S_i^2} < G_{\text{табл}} = G_{\alpha; v_1=m-1; v_2=n}$
- 3) определяется дисперсия адекватности: $S_{\text{ад}}^2 = \frac{\sum_{i=1}^n (\bar{y}_i - \bar{y})^2}{n-l}$
- 4) определяется дисперсия воспроизводимости: $S_{\text{восп}}^2 = \frac{\sum_{i=1}^n S_i^2}{n}$
- 5) проверка модели (полученного уравнения) на адекватность по критерию Фишера:

если $F_{\text{расч}} = \frac{S_{\text{ад}}^2}{S_{\text{восп}}^2} < F_{\text{табл}} = F_{\alpha; v_1=n-l; v_2=m(n-1)}$, то уравнение регрессии адекватно, в противном случае — нет.

Надежность оценок b_i уравнения регрессии можно охарактеризовать их доверительными интервалами Δb_i , в которых с заданной вероятностью находится истинное значение этого параметра.

Наиболее просто построить доверительные интервалы для параметров линейного уравнения регрессии, т.е. коэффициентов b_0 и b_1 .

При этом предполагается, что для каждого значения случайной величины $x = x_i$ имеется распределение со средним значением $\hat{y}_i = b_0 + b_1 x_i$ и дисперсией $S_{y_i}^2 = S_{\text{восп}}^2$.

Иными словами, делается допущение, что случайная величина Y распределена нормально при каждом значении x_i , а дисперсия $S_{y_i}^2 = \text{const}$ во всем интервале изменения x .

Для линейного уравнения среднеквадратичное отклонение i – го коэффициента уравнения регрессии S_{b_i} можно определить по закону накопления ошибок:

$$S_{b_i} = \sqrt{\sum_{j=1}^n \left(\frac{\partial b_j}{\partial y_i} \right)^2 S_j^2}$$

При условии, что $S_{y_1}^2 = S_{y_1}^2 = \dots = S_{y_n}^2 = S_{\text{восп}}^2$, получим:

$$S_{b_0} = \sqrt{\frac{S_{\text{восп}}^2 \sum_{i=1}^n x_i^2}{n \sum_{i=1}^n x_i^2 - (\sum_{i=1}^n x_i)^2}}; S_{b_1} = \sqrt{\frac{S_{\text{восп}}^2 n}{n \sum_{i=1}^n x_i^2 - (\sum_{i=1}^n x_i)^2}}$$

$$\text{или для Примера 1: } S_{b_0} = \sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2 \sum_{i=1}^n x_i^2}{(n-2)n \sum_{i=1}^n (x_i - \bar{x})^2}} = 39,9468; S_{b_1} = \sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{(n-2) \sum_{i=1}^n (x_i - \bar{x})^2}} = 0,1691$$

2. Проверка гипотезы о значимости коэффициентов уравнения регрессии.

Постановка задачи:

Нулевая гипотеза H_0 : «Коэффициент уравнения регрессии значим»

Альтернативная гипотеза $\bar{H}$: «Коэффициент уравнения регрессии незначим»

Требуется проверить гипотезу H_0 при заданном уровне значимости α .

Значимость коэффициентов полученного уравнения регрессии оценивается с использованием t -критерия Стьюдента:

$$t_{b_0 \text{ расч}} = \frac{b_0}{S_{b_0}} = \frac{121,4563}{39,9468} = 3,0404 > 2,2010 = t_{\text{табл}} = t_{\alpha; v=n-1} = t_{0,05;11} \quad \Delta b_0 = t_{\alpha; v=n-1} S_{b_0} = 87,9224$$

=СТЮДЕНТ.ОБР.2Х(0,05;11)

$$t_{b_1 \text{ расч}} = \frac{b_1}{S_{b_1}} = \frac{2,6098}{0,1691} = 15,4353 > 2,2010 = t_{\text{табл}} = t_{\alpha; v=n-1} = t_{0,05;11} \quad \Delta b_1 = t_{\alpha; v=n-1} S_{b_1} = 0,3721$$

Приведение нелинейных функций к линейному виду

Исходная формула	Преобразованная формула	Замена переменных	Линеаризованная формула
$y = b_0 + b_1 \ln(x)$	-	$\ln(x) = x_1$	$y = b_0 + b_1 x_1$
$y = \frac{1}{b_0 + b_1 x}$	$\frac{1}{y} = b_0 + b_1 x$	$\frac{1}{y} = y_1$	$y_1 = b_0 + b_1 x$
$y = b_0 x^{b_1}$	$\ln(y) = \ln(b_0) + b_1 \ln(x)$	$\ln(y) = y_1 \quad \ln(b_0) = b_0^* \quad \ln(x) = x_1$	$y_1 = b_0^* + b_1 x_1$
$y = b_0 + b_1 x^n$	-	$x_1 = x^n$	$y = b_0 + b_1 x_1$
$y = b_0 b_1^x$	$\ln(y) = \ln(b_0) + \ln(b_1)x$	$\ln(y) = y_1 \quad \ln(b_0) = b_0^* \quad \ln(b_1) = b_1^*$	$y_1 = b_0^* + b_1^* x$
$y = b_0 e^{b_1 x}$	$\ln(y) = \ln(b_0) + b_1 x$	$\ln(y) = y_1 \quad \ln(b_0) = b_0^*$	$y_1 = b_0^* + b_1 x$
$y = e^{b_0 + b_1 x}$	$\ln(y) = b_0 + b_1 x$	$\ln(y) = y_1$	$y_1 = b_0 + b_1 x$
$y = \frac{x}{b_0 + b_1 x}$	$\frac{1}{y} = \frac{b_0}{x} + b_1$	$\frac{1}{y} = y_1 \quad \frac{1}{y} = x_1 \quad b_0^* = b_1 \quad b_1^* = b_0$	$y_1 = b_0^* + b_1^* x_1$

Задача 1.

На основе результатов ультразвукового контроля (таблица 1) требуется исследовать зависимость $U = f(h)$




Таблица - Результаты ультразвукового контроля

h , мм	25	20	15	10	5
U_0 , у. е.	8,103	8,108	8,101	8,105	8,107
U , у. е.	0,003	0,015	0,069	0,351	1,668
t , мкс	7,92	6,33	4,75	3,17	1,59

Сплав – АМг6

Дефектоскоп – УСД-60

ПЭП – 10 МГц

Задача 2.

На основании данных ФСТЭК РФ (<https://bdu.fstec.ru/>) требуется исследовать зависимости угроз и уязвимостей за период 2023 - 2025 годов при уровне значимости $\alpha = 0,05$.

**Спасибо
за внимание!**

itmo *re than a*
UNIVERSITY

Федоров Алексей Владимирович
avfedorov@itmo.ru