



Статистические методы в инженерных исследованиях

Лабораторная работа 3

Обработка результатов пассивного эксперимента.

Дисперсионный и корреляционный анализ

Цель лабораторной работы: Получить умения и отработать навыки методов дисперсионного и корреляционного анализа.

Задачи лабораторной работы:

1. Провести пассивные эксперименты.
2. Обработать результаты пассивных экспериментов.
3. Оформить отчет по лабораторной работе.

Дисперсионный анализ применяется для исследования влияния одной или нескольких качественных переменных (факторов) на одну зависимую количественную переменную (отклик).

Корреляционный анализ – это группа статистических методов, направленная на выявление и математическое представление структурных зависимостей между выборками.

Регрессионный анализ - это статистический метод, устанавливающий количественно форму зависимости двух случайных величин, между которыми существует корреляционная связь.

Регрессионные процедуры позволяют рассчитать модель, описываемую некоторым уравнением и отражающую функциональную зависимость между экспериментальными количественными переменными, а также проверяют гипотезу об адекватности модели экспериментальным данным. По полученным результатам можно оценить природу и степень зависимости переменных и предсказать новые значения зависимой переменной.

Анализ временных рядов применим к одиночным или связанным временным рядам и позволяет выделять различные формы периодичности и взаимовлияния временных процессов, а также осуществлять **прогнозирование** будущего поведения временного ряда.

Кластерный анализ осуществляет разбиение объектов на заданное число удаленных друг от друга классов, а также строит дерево классификаций объектов посредством иерархического объединения их в группы (кластеры).

Основной задачей **факторного анализа** является нахождение в многомерном пространстве первичных переменных (значения которых регистрируются в эксперименте), сокращенной системы вторичных переменных (факторов).

Дисперсионный анализ – это анализ изменчивости признака под влиянием каких-либо контролируемых переменных факторов. **Дисперсионный анализ** является статистическим методом, предназначенным для выявления влияния ряда отдельных факторов на результаты экспериментов.

В основе дисперсионного анализа лежит предположение о том, что одни переменные могут рассматриваться как причины (факторы, независимые переменные), а другие как следствия (зависимые переменные). Независимые переменные называют иногда регулируемыми факторами именно потому, что в эксперименте исследователь имеет возможность варьировать ими и анализировать получающийся результат.

Сущность дисперсионного анализа заключается в расчленении общей дисперсии изучаемого признака на отдельные компоненты, обусловленные влиянием конкретных факторов, и проверке гипотез о значимости влияния этих факторов на исследуемый признак.

Исходным материалом для дисперсионного анализа служат данные исследования выборок, которые могут быть как **равными**, так и **неравными** по численности, как **связными**, так и **несвязными**.

По количеству выявляемых регулируемых факторов дисперсионный анализ может быть **однофакторным** (при этом изучается влияние одного фактора на результаты эксперимента), **двухфакторным** (при изучении влияния двух факторов) и **многофакторным** (позволяет оценить не только влияние каждого из факторов в отдельности, но и их взаимодействие).

Дисперсионный анализ относится к группе параметрических методов и поэтому его следует применять только тогда, когда доказано, что распределение является нормальным.

Почему дисперсионный анализ называется дисперсионным?

При дисперсионном анализе исследуется отношение двух дисперсий и определяют удельный вес суммарного воздействия одного или нескольких факторов	
Первая дисперсия (межгрупповая) – дисперсия объясненная влиянием фактора, которая характеризует рассеивание значений между градациями фактора (группами) вокруг средней всех данных	Вторая дисперсия (внутригрупповая) – дисперсия необъясненная , которая характеризует рассеивание данных внутри градаций (групп) вокруг средних значений самих групп
Отношение этих дисперсий называется фактическим отношением (критерием) Фишера и сравнивается с критическим значением отношения (критерием) Фишера	
Если $F_{\text{расч}} < F_{\text{табл}}$, то средние классов градации не отличаются друг от друга и исследуемый фактор существенно не влияет на изменение данных	Если $F_{\text{расч}} > F_{\text{табл}}$, то средние классов градации отличаются друг от друга и фактор имеет существенное влияние на изменение данных

Постановка задачи:

Нулевая гипотеза $H_0: M_1 = M_2 = \dots = M_k$, где k - число классов градации и все классы градации имеют одно значение средних.

Альтернативная гипотеза $\bar{H}: M_1 \neq M_2 \neq \dots \neq M_k$, не все классы градации имеют одно значение средних (по крайней мере одно среднее значение отличается от остальных).

Однофакторный дисперсионный анализ

Основан на том, что сумму квадратов отклонений статистического комплекса возможно разделить на компоненты:

$$SS = SS_k + SS_e,$$

где $SS = \sum_i^k \sum_j^{n_i} (x_{ij} - \bar{x})^2$ - общая сумма квадратов отклонений;

$SS_k = \sum_j^{n_i} n_i (\bar{x}_i - \bar{x})^2$ - объясненная влиянием фактора K сумма квадратов отклонений;

$SS_e = \sum_i^k \sum_j^{n_i} (x_{ij} - \bar{x}_i)^2$ - необъясненная сумма квадратов отклонений или сумма квадратов отклонений ошибки;

$n = \sum_i^k n_i$; $\bar{x} = \frac{1}{kn} \sum_i^k \sum_j^{n_i} x_{ij} = \frac{1}{k} \sum_i^k \bar{x}_i$ - общее среднее наблюдений; $\bar{x}_i = \frac{1}{n_i} \sum_j^{n_i} x_{ij}$ - среднее наблюдений в каждой градации фактора K

Кроме того: $SS_e = \sum_i^k \sum_j^n (x_{ij} - \bar{x}_i)^2 = \sum_i^k (n_i - 1) S_i^2 = (n_1 - 1) S_1^2 + (n_2 - 1) S_2^2 + \dots + (n_k - 1) S_k^2$,

где S_i^2 - дисперсия градации фактора (группы).

Дисперсии рассчитываются следующим образом:

$S^2 = SS/v = SS/n-1$ - общая дисперсия;

$S_k^2 = SS_k/v_k = SS_k/k-1$ - объясненная дисперсия;

$S_e^2 = SS_e/v_e = SS_e/n-k$ - необъясненная дисперсия (дисперсия ошибки).

$$F_{\text{расч}} = \frac{S_k^2}{S_e^2} < F_{\text{табл}} = F_{\alpha; v_k; v_e}$$

Пример 1.

Дано: Для оценки работы трех отрезных станков проведены замеры на соответствия по длине полученных сортиментов установленным требованиям, при этом фиксировалась величина отклонения фактического размера сортимента от номинального размера. Результаты замеров представлены в таблице 7.1.

Таблица 7.1

i	$k = 3$	x_{ij}										n_i
		1	2	3	4	5	6	7	8	9	10	
1	Станок 1	0,4	0,5	0,5	0,3	0,4						5
2	Станок 2	0,5	0,4	0,3	0,6	0,8	0,5	0,7	0,6	0,7	0,4	10
3	Станок 3	0,6	0,4	0,7	0,5	0,4	0,6	0,5	0,8			8

Найти: Влияние различий в настройках станков на точность работы станков по отрезке сортиментов номинальной длины при уровне значимости $\alpha = 0,05$.

Решение:

i	$k = 3$	x_{ij}										n_i	n	$\bar{x}_i$	$\bar{\bar{x}}$	SS	SS_k	SS_e	S^2	S_k^2	S_e^2
		1	2	3	4	5	6	7	8	9	10										
1	Станок 1	0,4	0,5	0,5	0,3	0,4						5	23	0,42	0,53	0,46	0,07	0,39	0,0211	0,0363	0,0196
2	Станок 2	0,5	0,4	0,3	0,6	0,8	0,5	0,7	0,6	0,7	0,4	10		0,55							
3	Станок 3	0,6	0,4	0,7	0,5	0,4	0,6	0,5	0,8			8		0,56							

$$F_{\text{расч}} = \frac{0,0363}{0,0196} = 1,85 < F_{\text{табл}} = F_{0,05;2;20} = 3,49$$

Вывод: С вероятностью 0,95 можем принять, что настройка станков не влияет на точность их работы.

Лабораторная работа 3 - Microsoft Excel (Свой активации продукта)

Файл Главная Вставка Разметка страницы Формулы Данные Рецензирование Вид

Получение внешних данных Подключения Сортировка и фильтр Работа с данными Структура Анализ

В3

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T
1	Пример 1													Однофакторный дисперсионный анализ						
2			1	2	3	4	5	6	7	8	9	10								
3	1	Станок 1	0,4	0,5	0,5	0,3	0,4							ИТОГИ						
4	2	Станок 2	0,5	0,4	0,3	0,6	0,8	0,5	0,7	0,6	0,7	0,4		Группы	Счет	Сумма	Среднее	Дисперсия		
5	3	Станок 3	0,6	0,4	0,7	0,5	0,4	0,6	0,5	0,8				Станок 1	5	2,1	0,42	0,01		
6														Станок 2	10	5,5	0,55	0,03		
7														Станок 3	8	4,5	0,56	0,02		
8																				
9																				
10														Дисперсионный анализ						
11														Источник вариации	SS	df	MS	F	P-Значение	F критическое
12														Между группами	0,07	2	0,0363	1,85	0,18	3,49
13														Внутри групп	0,39	20	0,0196			
14																				
15														Итого	0,46	22				
16																				
17																				
18																				
19																				

Двухфакторный дисперсионный анализ без повтор... ? X

Входные данные: \$B\$3:\$L\$5

Входной интервал: \$B\$3:\$L\$5

☒ Метки

Альфа: 0,05

Параметры вывода:

☒ Выходной интервал: \$F\$1

☐ Новый рабочий лист:

☐ Новая рабочая книга

ОК Отмена Справка

Лист1 Пример 1 / Пример 2

17:06 31.03.2023

Двухфакторный дисперсионный анализ без повторений:

Двухфакторный дисперсионный анализ применяется для того, чтобы проверить возможную зависимость результативного признака от двух факторов - A и B . Тогда a - число градаций фактора A и b - число градаций фактора B . В статистическом комплексе сумма квадратов остатков разделяется на три компоненты:

$$SS = SS_a + SS_b + SS_e,$$

где $SS = \sum_i^a \sum_j^b (x_{ij} - \bar{\bar{x}})^2$ - общая сумма квадратов отклонений;

$SS_a = b \sum_i^a (\bar{x}_i - \bar{\bar{x}})^2$ - объясненная влиянием фактора A сумма квадратов отклонений;

$SS_b = a \sum_j^b (\bar{x}_j - \bar{\bar{x}})^2$ - объясненная влиянием фактора B сумма квадратов отклонений;

$SS_e = \sum_i^a \sum_j^b (x_{ij} - \bar{x}_i - \bar{x}_j + \bar{\bar{x}})^2$ - необъясненная сумма квадратов отклонений или сумма квадратов отклонений ошибки;

$\bar{\bar{x}} = \frac{1}{ab} \sum_i^a \sum_j^b x_{ij}$ - общее среднее наблюдений; $\bar{x}_i = \frac{1}{b} \sum_j^b x_{ij}$ - среднее наблюдений в каждой градации фактора A ; $\bar{x}_j = \frac{1}{a} \sum_i^a x_{ij}$ - среднее наблюдений в каждой градации фактора B .

Дисперсии рассчитываются следующим образом:

$S^2 = SS/v = SS/_{ab-1}$ - общая дисперсия;

$S_a^2 = SS_a/v_a = SS_a/_{a-1}$ - дисперсия, объясненная влиянием фактора A ;

$S_b^2 = SS_b/v_b = SS_b/_{b-1}$ - дисперсия, объясненная влиянием фактора B ;

$S_e^2 = SS_e/v_e = SS_e/_{(a-1)(b-1)}$ - необъясненная дисперсия (дисперсия ошибки).

$$F_{\text{расч.}a} = \frac{S_a^2}{S_e^2} < F_{\text{табл}} = F_{\alpha; v_a; v_e}$$

$$F_{\text{расч.}b} = \frac{S_b^2}{S_e^2} < F_{\text{табл}} = F_{\alpha; v_b; v_e}$$

Таблица 10.1

		В – число степеней свободы		
		1-2	3-4	5-6
А - тип привода	электрический	0,1	0,3	0,5
	гидравлический	0,2	0,6	1,0
	пневматический	0,3	0,9	1,5

Пример 2.

Дано: Дана информация о точности движения РТК (промышленного робота) в зависимости от типа привода и числа степеней свободы (таблице 10.1).

Найти: Зависит ли точность движения РТК (промышленного робота) от типа привода и числа степеней свободы при уровне значимости $\alpha = 0,05$.

Решение:

		В – число степеней свободы			$\bar{x}_i$	SS	SS _a	SS _b	SS _e	S ²	S _a ²	S _b ²	S _e ²
		1-2	3-4	5-6									
А - тип привода	электрический	0,1	0,3	0,5	0,3	1,66	0,54	0,96	0,16	0,21	0,27	0,48	0,04
	гидравлический	0,2	0,6	1,0	0,6								
	пневматический	0,3	0,9	1,5	0,9								
	$\bar{x}_j$	0,2	0,6	1,0	$\bar{\bar{x}} = 0,6$								

$$F_{\text{расч.}a} = \frac{0,27}{0,04} = 6,75 < F_{\text{табл}} = F_{0,05;2;4} = 6,94$$

$$F_{\text{расч.}b} = \frac{0,48}{0,04} = 12,00 > F_{\text{табл}} = F_{0,05;2;4} = 6,94$$

Вывод: С вероятностью 0,95 можем принять, что тип привода не влияет, а число степеней свободы влияет на точность движения РТК (промышленного робота).

Лабораторная работа 3 - Microsoft Excel (Своей активацией продукта)

Файл Главная Вставка Разметка страницы Формулы Данные Рецензирование Вид

Из Access Из Интернета Из других источников Существующие Подключения Обновить все Подключения Свойства Изменить связи Подключения Сортировка и фильтр Фильтр Очистить Повторить Дополнительно Текст по столбцам Удалить дубликаты Проверка Консолидация Анализ "что если" Группировать Разгруппировать Промежуточный итог Структура Анализ данных Анализ

А2

	A	B	C	D	E	F	G	H	I	J	K	L	M	N
1	Пример 2				Двухфакторный дисперсионный анализ без повторений									
2		1-2 ст	3-4 ст	5-6 ст										
3	Электро	0,1	0,3	0,5										
4	Гидро	0,2	0,6	1,0										
5	Пневмо	0,3	0,9	1,5										
6														
7														
8														
9														
10														
11														
12														
13														
14														
15														
16														
17														
18														
19														
20														
21														
22														
23														

Двухфакторный дисперсионный анализ без повторений

ИТОГИ	Счет	Сумма	Среднее	Дисперсия
Электро	3	0,9	0,3	0,04
Гидро	3	1,8	0,6	0,16
Пневмо	3	2,7	0,9	0,36
1-2 ст	3	0,6	0,2	0,01
3-4 ст	3	1,8	0,6	0,09
5-6 ст	3	3,0	1,0	0,25

Дисперсионный анализ

Источник вариации	SS	df	MS	F	P-Значение	F критическое
Строки	0,54	2	0,27	6,75	0,05	6,94
Столбцы	0,96	2	0,48	12,00	0,02	6,94
Погрешность	0,16	4	0,04			
Итого	1,66	8				

Двухфакторный дисперсионный анализ без повторений

Входные данные:

Входной интервал: A4:B15

☒ Метки

Дельта: 0,05

Параметры вывода:

☒ Выходной интервал: \$F\$1

☐ Новый рабочий лист:

☐ Новая рабочая книга

ОК Отмена Справка

Лист1: Пример 1 Пример 2

Укажите

17:05 31.03.2023

Двухфакторный дисперсионный анализ с повторениями:

Двухфакторный дисперсионный анализ с повторениями применяется для того, чтобы проверить не только возможную зависимость результативного признака от двух факторов - A и B , но и возможное взаимодействие факторов A и B . Тогда a - число градаций фактора A и b - число градаций фактора B , r - число повторений. В статистическом комплексе сумма квадратов остатков разделяется на четыре компоненты:

$$SS = SS_a + SS_b + SS_{ab} + SS_e,$$

где $SS = \sum_i^a \sum_j^b \sum_k^r (x_{ijk} - \bar{x})^2$ - общая сумма квадратов отклонений;

$SS_a = br \sum_i^a (\bar{x}_i - \bar{x})^2$ - объясненная влиянием фактора A сумма квадратов отклонений;

$SS_b = ar \sum_j^b (\bar{x}_j - \bar{x})^2$ - объясненная влиянием фактора B сумма квадратов отклонений;

$SS_{ab} = r \sum_i^a \sum_j^b (x_{ij} - \bar{x}_i - \bar{x}_j + \bar{x})^2$ - объясненная влиянием взаимодействия факторов A и B сумма квадратов отклонений;

$SS_e = \sum_i^a \sum_j^b \sum_k^r (x_{ijk} - \bar{x}_{ij})^2$ - необъясненная сумма квадратов отклонений или сумма квадратов отклонений ошибки;

$\bar{x} = \frac{1}{abr} \sum_i^a \sum_j^b \sum_k^r x_{ijk}$ - общее среднее наблюдений;

$\bar{x}_i = \frac{1}{br} \sum_j^b \sum_k^r x_{ijk}$ - среднее наблюдений в каждой градации фактора A ;

$\bar{x}_j = \frac{1}{ar} \sum_i^a \sum_k^r x_{ijk}$ - среднее наблюдений в каждой градации фактора B ;

$\bar{x}_{ij} = \frac{1}{r} \sum_k^r x_{ijk}$ - среднее число наблюдений в каждой комбинации градаций факторов A и B .

Дисперсии рассчитываются следующим образом:

$$S^2 = SS/v = SS/_{abr-1} - \text{общая дисперсия};$$

$$S_a^2 = SS_a/v_a = SS_a/_{a-1} - \text{дисперсия, объясненная влиянием фактора A};$$

$$S_b^2 = SS_b/v_b = SS_b/_{b-1} - \text{дисперсия, объясненная влиянием фактора B};$$

$$S_{ab}^2 = SS_{ab}/v_{ab} = SS_{ab}/_{(a-1)(b-1)} - \text{дисперсия, объясненная взаимодействием факторов A и B}$$

$$S_e^2 = SS_e/v_e = SS_e/_{ab(r-1)} - \text{необъясненная дисперсия (дисперсия ошибки)}.$$

$$F_{\text{расч.}a} = \frac{S_a^2}{S_e^2} < F_{\text{табл}} = F_{\alpha;v_a;v_e}$$

$$F_{\text{расч.}b} = \frac{S_b^2}{S_e^2} < F_{\text{табл}} = F_{\alpha;v_b;v_e}$$

$$F_{\text{расч.}ab} = \frac{S_{ab}^2}{S_e^2} < F_{\text{табл}} = F_{\alpha;v_{ab};v_e}$$

Пример 3.

Дано: Выборочные данные о пластичности материала изготовленного на различных предприятиях, в который добавлялся пластификатор (элемент) с различным процентным составом и которые подвергались различным способам химической обработки, представлены в таблице 14.1.

Найти: При уровне значимости $\alpha = 0,05$ выяснить, влияют ли на пластичность материала технологии химической обработки.

Таблица 14.1

Номер пред- приятия	А - вид элемента	В – способ химической обработки		
		Способ 1	Способ 2	Способ 3
1	Элемент 1	21,4	20,9	17,6
2		21,2	20,3	16,6
3		20,1	19,8	17,4
1	Элемент 2	12,1	13,6	13,3
2		14,2	13,3	14,1
3		12,3	12,6	13,8
1	Элемент 3	13,5	14,0	12,4
2		11,9	15,6	13,7
3		13,4	13,8	13,1

Решение:

Лабораторная работа_3 - Microsoft Excel (Свой активации продукта)

Файл Главная Вставка Разметка страницы Формулы Данные Рецензирование Вид

Получение внешних данных Подключения Структура Анализ

В14

Номер предприятия	А - вид элемента	В – способ химической обработки			ИТОГИ
		Способ 1	Способ 2	Способ 3	
1	Элемент 1	21,4	20,9	17,6	Счет
2		21,2	20,3	16,6	Сумма
3		20,1	19,8	17,4	Среднее
1	Элемент 2	12,1	13,6	13,3	Дисперсия
2		14,2	13,3	14,1	
3		12,3	12,6	13,8	
1	Элемент 3	13,5	14	12,4	Счет
2		11,9	15,6	13,7	Сумма
3		13,4	13,8	13,1	Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия
					Счет
					Сумма
					Среднее
					Дисперсия

Задача 1. На заводе разработаны два новых варианта технологического процесса. Чтобы оценить, как изменится дневная производительность при переходе на работу по новым технологиям, завод в течение 10 дней работает по каждому варианту, включая существующий. Дневная производительность завода (в условных единицах) представлена в таблице 16.1.

При уровне значимости $\alpha = 0,05$ требуется выяснить, как зависит дневная производительность от технологического процесса и оценить степень этой зависимости.

Таблица 16.1

<i>День работы</i>	<i>Дневная производительность</i>		
	<i>Существующая технология</i>	<i>Вариант 1</i>	<i>Вариант 2</i>
1	119	83	76
2	66	128	149
3	96	176	97
4	174	106	77
5	71	96	114
6	101	172	197
7	135	81	179
8	171	163	154
9	148	73	112
10	84	108	109

Задача 2. В процессе производства получается побочный нежелательный продукт, процентное содержание которого измеряется четырьмя различными катализаторами при трех уровнях температуры. Данные о процентном содержании побочного продукта представлены в таблице 17.1.

Требуется при уровне значимости $\alpha = 0,05$ определить, что оказывает более значимое влияние на выявление побочного продукта (катализатор или уровень температуры).

Таблица 17.1

<i>Уровень температуры</i>	<i>Катализатор 1</i>	<i>Катализатор 2</i>	<i>Катализатор 3</i>	<i>Катализатор 4</i>
<i>Высокий</i>	1,31	1,22	1,05	1,18
<i>Средний</i>	1,13	1,09	1,26	1,24
<i>Низкий</i>	1,26	1,04	1,14	1,06

Задача 3. Оценка уровня качества средств криптографической защиты информации (СКЗИ) осуществлялась методом тестирования на трех предприятиях. Для защиты информации использовались программно-аппаратные средства различных типов. При тестировании оценивался уровень (процент) нарушения безопасности информации при ее обработке СКЗИ (таблица 18.1).

При уровне значимости $\alpha = 0,05$ выяснить влияние программных и аппаратных средств на защиту информации.

Таблица 18.1

		Техническое средство 1	Техническое средство 2	Техническое средство 3
Предприятие 1	Программа 1	10	14	16
Предприятие 2		11	12	14
Предприятие 3		10	11	15
Предприятие 1	Программа 2	9	10	14
Предприятие 2		8	14	12
Предприятие 3		10	11	13
Предприятие 1	Программа 3	18	20	22
Предприятие 2		16	18	20
Предприятие 3		17	18	18

Основными задачами корреляционного анализа являются выявление связи между переменными и оценка тесноты этой связи.

Корреляционная зависимость – это зависимость между одной случайной переменной и условным средним значением другой переменной.

В корреляционном анализе существуют следующие допущения:

- 1) переменные x и y являются случайными величинами, распределенными по нормальному закону;
- 2) некоторому значению x можно поставить в соответствие одно или несколько значений y ;
- 3) по данному нормальному распределению случайных величин x и y можно определить выборочное среднее и среднеквадратичное отклонение величин x и y .

Коэффициент корреляции (Пирсон):

$$r_{xy} = \frac{cov_{xy}}{S_y S_x} = \frac{1}{n-1} \frac{\sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x})}{S_y S_x} = \frac{\sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x})}{\sqrt{\sum_{i=1}^n (y_i - \bar{y})^2 \sum_{i=1}^n (x_i - \bar{x})^2}}$$

$cov_{xy} = M[(x - M_x)(y - M_y)] = M_{xy} - M_x - M_y$ - **ковариация** (или **корреляционный момент**), которая является совместным центральным второго порядка и определяется как математическое ожидание отклонений произведения отклонений случайных величин.

Коэффициент детерминации (R^2) — это доля дисперсии зависимой переменной, объясняемая рассматриваемой моделью зависимости, то есть объясняющими переменными.

$$R^2 = 1 - \frac{S^2}{S_y^2} = 1 - \frac{S_{\text{уст}}^2}{S_y^2}$$

где S^2 ($S_{\text{уст}}^2$) - условная (по факторам x) дисперсия зависимой переменной (дисперсия ошибки модели).

S_y^2 - дисперсия случайной величины y .

Если использовать выборочную оценку значений соответствующих дисперсий, то получим формулу для выборочного коэффициента детерминации (который обычно и подразумевается под R^2):

$$R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}}$$

Или (в смысле дисперсионного анализа) R^2 - это доля объяснённой суммы квадратов в общей: $R^2 = \frac{SS_{\text{reg}}}{SS_{\text{tot}}}$

SS_{res} - сумма квадратов остатков (отклонений ошибки) ;

SS_{reg} - объясненная сумма квадратов отклонений;

SS_{tot} - общая сумма квадратов отклонений.

Решение:

Вывод: с вероятностью 0,95 можем пр

- 1) вид пластификатора (элемент пластичность материала;
- 2) способ химической обработки пластичность материала;
- 3) результативность различных пластификаторов (элементов) зависимости от способа химическ
- 4) выборочный коэффициент детерм

$$R^2 = \frac{SS_{\text{выборка}}}{SS_{\text{итого}}} = \frac{223,91}{263,32} = 0,85$$

показывает, что на 85% всей выборочн
пластичности материала влияет вид пл

В случае линейной зависимости R^2 является квадратом так называемого множественного коэффициента корреляции между зависимой переменной и объясняющими переменными.

В частности, для модели парной линейной регрессии $R^2 = r_{xy}^2$.

Метод вычисления коэффициента корреляции зависит от вида шкалы, к которой относятся переменные.

Типы шкал		Показатель
Переменная X	Переменная Y	
Интервальная или отношений	Интервальная или отношений	Коэффициент корреляции Пирсона
Ранговая, интервальная или отношений	Ранговая, интервальная или отношений	Коэффициент корреляции рангов Спирмена
Ранговая	Ранговая	Коэффициент корреляции Кендалла
Дихотомическая	Дихотомическая	Коэффициент ассоциации
Дихотомическая	Ранговая	Рангово-бисериальный коэффициент корреляции
Дихотомическая	Интервальная или отношений	Бисериальный коэффициент корреляции
Интервальная	Ранговая	Не разработан

Ранговая корреляция — это взаимосвязь между ранжированием различных порядковых переменных или различными ранжированиями одной и той же переменной, где под «ранжированием» понимается присвоение меток порядка «первый», «второй» и т.д. к различным наблюдениям за конкретной переменной.

Коэффициент ранговой корреляции измеряет степень сходства между двумя рейтингами и может использоваться для оценки значимости связи между ними.

При изучении статистической зависимости обычно ограничиваются исследованием усредненной зависимости (Как в среднем будет изменяться значение одной величины при изменении другой?). Такая зависимость называется **регрессионной**.

Более строго, **регрессионная зависимость между двумя случайными величинами** — это функциональная зависимость между значениями одной из них и условным математическим ожиданием другой.

На практике по экспериментальным данным можно найти только оценку (приближенное выражение) функции регрессии, т.е. по выборке определяют **выборочное (эмпирическое) уравнение регрессии**.

Как правило, до проведения эксперимента выбирают вид выборочной функции регрессии с точностью до нескольких параметров, а значения параметров определяют по выборке.

Вид эмпирической функции регрессии определяют исходя из:

- 1) теоретических соображений о физической сущности исследуемой зависимости;
- 2) опыта предыдущих исследований;
- 3) характера расположения точек на **корреляционном поле**, которое получается, если отметить на плоскости все точки с координатами $(x_i; y_i)$, соответствующие наблюдениям.

Наибольший интерес представляет линейное эмпирическое уравнение регрессии, поскольку:

- 1) это наиболее простой случай для расчетов и анализа;
- 2) при нормальном распределении модельная функция регрессии является линейной.

Выборочный коэффициент корреляции Пирсона:
$$r_{xy} = \frac{cov_{xy}}{S_y S_x} = \frac{1}{n-1} \frac{\sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x})}{S_y S_x} = \frac{\sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x})}{\sqrt{\sum_{i=1}^n (y_i - \bar{y})^2 \sum_{i=1}^n (x_i - \bar{x})^2}}$$

служит количественной мерой линейной связи между двумя наблюдаемыми величинами x и y .

Выборочный коэффициент корреляции обладает следующими свойствами:

- ☐ $|r_{xy}| \leq 1$;
- ☐ если r_{xy} близок к единице, то наблюдаемые величины x и y связаны линейной зависимостью $y = b_0 + b_1 x$;
- ☐ если $r_{xy} = 0$, то наблюдаемые величины независимы.

Часто теснота связи величин оценивается по шкале Чеддока.

$ r_{xy} $	Характеристика силы (тесноты) связи
0,01- 0,09	Незначительная
0,10 - 0,29	Слабая
0,30 - 0,49	Умеренная
0,50 - 0,69	Средняя
0,70 - 0,89	Сильная
0,90 - 0,99	Очень сильная

Коэффициент корреляции является мерой именно линейной зависимости. Когда точки образуют кривые линии, т. е. зависимость между переменными хотя и явно присутствует, но отличается от линейной, коэффициент корреляции не равен единице по абсолютной величине.

В случае нелинейной зависимости связь между величиной коэффициента корреляции и близостью точек корреляционного поля к некоторой линии не прослеживается. Поэтому в практических задачах при выборе вида эмпирической функции регрессии обязательно учитывают характер расположения точек на корреляционном поле.

Проверка значимости коэффициента корреляции (т. е., значимо ли отличается выборочный коэффициент корреляции от нуля) производится в случае выборки из нормального распределения по критерию Стьюдента.

Постановка задачи:

Нулевая гипотеза $H_0 : r_{xy} = 0$

Альтернативная гипотеза $\bar{H} : r_{xy} \neq 0$

Гипотезу H_0 по выборке объема n при заданном уровне значимости α принимают, если:

$$t_{\text{расч}} = \frac{|r_{xy}|}{s_r} = |r_{xy}| \sqrt{\frac{n-2}{1-r_{xy}^2}} < t_{\text{табл}} = t_{\alpha; \nu=n-2}$$

$$s_r = \sqrt{\frac{1-r_{xy}^2}{n-2}}$$

s_r - ошибка коэффициента корреляции.

Если $t_{\text{расч}} > t_{\text{табл}}$, то считают, что коэффициент корреляции значимо отличается от нуля, а следовательно, связь между наблюдаемыми величинами является статистически значимой.

Если коэффициент корреляции значим, то целесообразно определить доверительный интервал (интервальную оценку) с заданным уровнем доверительной вероятности (значимости).

При большом объеме выборки ($n \geq 50$) рекомендуется построение доверительного интервала, которое производится по формуле:

$$r_{xy} + \frac{r_{xy}(1 - r_{xy}^2)}{2n} - t_{\alpha} \frac{(1 - r_{xy}^2)}{\sqrt{n}} \leq r_{xy} \leq r_{xy} + \frac{r_{xy}(1 - r_{xy}^2)}{2n} + t_{\alpha} \frac{(1 - r_{xy}^2)}{\sqrt{n}}$$

t_{α} - квантиль нормального распределения.

При малых объемах выборки ($n < 50$) рекомендуется построение доверительного интервала для r_{xy} , которое основано на z-преобразовании Фишера, которое производится по формуле:

$$Z = \frac{1}{2} \ln \left(\frac{1+r_{xy}}{1-r_{xy}} \right), \text{ при этом СКО случайной величины } Z \text{ зависит от числа опытов } n: S_Z = \frac{1}{\sqrt{n-3}}$$

Пересчитать пределы изменения r_{xy} можно, зная величину S_Z . По числу измерений x и y определяют величину коэффициента t_{α} , для заданной доверительной вероятности p рассчитывается интервал изменения величины S_Z : $\Delta S_Z = t_{\alpha} S_Z$

Пример 4.

Дано: Выборочные экспериментальные данные средних значений твердости H и предела прочности σ_B сталей различных марок, представлены в таблице.


Найти: построить поле корреляции, которое определяется значениями входных и выходных данных, рассчитать выборочный коэффициент корреляции, определить характеристику силы (тесноты) связи, определить значимость и найти доверительный интервал выборочного коэффициента корреляции при уровне значимости $\alpha = 0,05$ и доверительной вероятности $p = 0,95$.

Таблица

n	1	2	3	4	5	6
H, HB	111	144	172	190	173	205
$\sigma_B, МПа$	447	452	532	571	589	634
n	7	8	9	10	11	12
H, HB	193	257	240	285	314	398
$\sigma_B, МПа$	675	744	815	894	976	1128

Решение:

r_{xy}	0,9797	=КОРРЕЛ(С3:Н3;С4:Н4)
$cov(x; y)$	16700,68	=КОВАРИАЦИЯ.В(С3:Н3;С4:Н4)
S_x	80,0	=СТАНДОТКЛОН.В(С3:Н3)
S_y	213,1	=СТАНДОТКЛОН.В(С4:Н4)



n	1	2	3	4	5	6	7	8	9	10	11	12
H	111	144	172	190	173	205	193	257	240	285	314	398
σ_B	447	452	532	571	589	634	675	744	815	894	976	1128
$\bar{H}$	223,5											
$\bar{\sigma}_B$	704,8											
$H - \bar{H}$	-112,5	-79,5	-51,5	-33,5	-50,5	-18,5	-30,5	33,5	16,5	61,5	90,5	174,5
$\sigma_B - \bar{\sigma}_B$	-257,8	-252,8	-172,8	-133,8	-115,8	-70,8	-29,8	39,3	110,3	189,3	271,3	423,3
$(H - \bar{H})(\sigma_B - \bar{\sigma}_B)$	28996,88	20093,63	8896,63	4480,63	5845,38	1308,88	907,38	1314,88	1819,13	11638,88	24548,13	73857,13
$(H - \bar{H})^2$	12656,25	6320,25	2652,25	1122,25	2550,25	342,25	930,25	1122,25	272,25	3782,25	8190,25	30450,25
$(\sigma_B - \bar{\sigma}_B)^2$	66435,06	63882,56	29842,56	17889,06	13398,06	5005,56	885,06	1540,56	12155,06	35815,56	73576,56	179140,56
$\sum (H - \bar{H})(\sigma_B - \bar{\sigma}_B)$	183707,50											
$\sum (H - \bar{H})^2$	70391,00											
$\sum (\sigma_B - \bar{\sigma}_B)^2$	499566,25											
r_{xy}	0,9797											

$$t_{\text{расч}} = |r_{xy}| \sqrt{\frac{n-2}{1-r_{xy}^2}} = 0,9797 \sqrt{\frac{12-2}{1-0,9797^2}} = 15,4353 > t_{\text{табл}} = t_{0,05;10} = 2,2281$$

=СТЪЮДЕНТ.ОБР.2X(0,05;10)

$$Z = \frac{1}{2} \ln \left(\frac{1+r_{xy}}{1-r_{xy}} \right) = \frac{1}{2} \ln \left(\frac{1+0,9797}{1-0,9797} \right) = 2,2888$$

$$S_z = \frac{1}{\sqrt{n-3}} = \frac{1}{\sqrt{12-3}} = 0,3333$$

$$\Delta S_z = t_{\alpha} S_z = 1,96 \cdot 0,3333 = 0,7337$$

$$1,6355 \leq Z = 2,2888 \leq 2,9422$$

$$0,9268 \leq r_{xy} = 0,9797 \leq 0,9944$$

Корреляция называется **множественной**, если исследуется связь между тремя и более признаками. Наиболее простой формой множественной корреляции является зависимость между тремя признаками. Для определения формы и тесноты связи нескольких факторов применяют **частные и множественные коэффициенты корреляции**.

Частный коэффициент корреляции для трех признаков (факторов) определяет форму и тесноту связи между двумя при постоянном значении третьего. Обозначается частный коэффициент корреляции как $r_{xy.z}$, $r_{xz.y}$ и $r_{yz.x}$, где до точки указываются факторы, которые изучаются, после точки – фактор, значение которого элиминировается. Вычисляют частные коэффициенты корреляции по формулам:

$$r_{xy.z} = \frac{r_{xy} - r_{xz}r_{yz}}{\sqrt{(1-r_{xz}^2)(1-r_{yz}^2)}}; r_{xz.y} = \frac{r_{xz} - r_{xy}r_{zy}}{\sqrt{(1-r_{xy}^2)(1-r_{zy}^2)}}; r_{yz.x} = \frac{r_{yz} - r_{yx}r_{zx}}{\sqrt{(1-r_{yz}^2)(1-r_{zx}^2)}}$$

Множественный коэффициент корреляции показывает тесноту связи одного фактора с совокупностью двух других факторов, то есть зависимость одного фактора от двух других. Обозначается множественный коэффициент корреляции как $R_{x.yz}$, $R_{y.xz}$ и $R_{z.xy}$, где до точки указывается признак, который изучается, после точки – факторы, влияющие на изучаемый признак. Вычисляют множественные коэффициенты корреляции по формулам:

$$R_{x.yz} = \sqrt{\frac{r_{xy}^2 + r_{xz}^2 - 2r_{xy}r_{xz}r_{yz}}{1-r_{yz}^2}}; R_{y.xz} = \sqrt{\frac{r_{yx}^2 + r_{yz}^2 - 2r_{yx}r_{yz}r_{zx}}{1-r_{zx}^2}}; R_{z.xy} = \sqrt{\frac{r_{zx}^2 + r_{zy}^2 - 2r_{zx}r_{zy}r_{xy}}{1-r_{xy}^2}}$$

Значимость множественной корреляции проверяют по критерию Фишера: $F_{\text{расч}} = \frac{R^2}{1-R^2} \frac{n-k}{k-1} > F_{\alpha, v_1=k-1, v_2=n-k}$

Пример 5.

Дано: Распределение уязвимостей по типам ошибок CWE по месяцам в период с января по апрель 2022 года.

Требуется: Провести корреляционный анализ уязвимостей по типам ошибок при уровне значимости $\alpha = 0,05$.

2022 год	Тип ошибки CWE														
	20	416	787	79	269	125	94	200	476	190	78	119	362	120	264
январь	129	58	56	42	40	34	31	23	19	17	0	0	0	0	0
февраль	17	68	28	0	24	24	32	20	15	0	18	16	0	0	0
март	21	57	28	0	0	18	15	0	23	0	0	35	17	17	17
апрель	116	55	41	22	31	30	36	33	0	0	0	0	25	0	25
	283	238	153	64	95	106	114	76	57	17	18	51	42	17	42

Решение:

	20	416	787	79	269	125	94	200
20		-0,60	0,92	0,95	0,79	0,91	0,58	0,71
416			-0,43	-0,46	0,02	-0,22	0,16	-0,05
787				1,00	0,80	0,91	0,45	0,53
79					0,81	0,92	0,48	0,57
269						0,97	0,88	0,87
125							0,78	0,82
94								0,98
200								

20	787
20	79
20	125
416	78
787	78
787	125
79	125
269	125
269	119

269	120
125	119
94	200
94	119
94	120
200	119
200	120
362	264

20	787	125
20	79	125
269	125	119
94	200	119
94	200	120

$$r_{20-787,125} = 0,55$$

$$R_{20,787-125} = 0,94$$

Все рассмотренные коэффициенты корреляции служат для выявления линейной зависимости.

Для измерения нелинейной корреляционной связи между признаками используется корреляционное отношение, понятие которого ввел К. Пирсон.

Показатели корреляционного отношения вычисляются по формулам по формулам:

$$h_{yx} = \sqrt{\frac{\sum_{i=1}^n f_x(\bar{y}_x - \bar{y})^2}{\sum_{i=1}^n f_y(\bar{y}_i - \bar{y})^2}}; h_{xy} = \sqrt{\frac{\sum_{i=1}^n f_y(\bar{x}_y - \bar{x})^2}{\sum_{i=1}^n f_x(\bar{x}_i - \bar{x})^2}}$$

где f_x и f_y - частоты рядов X и Y; $\bar{y}_x$ и $\bar{x}_y$ - групповые средние рядов X и Y; $\bar{x}$ и $\bar{y}$ - средние рядов X и Y.

Алгоритм для вычисления корреляционного отношения

1. Расположить по порядку (от меньшей к большей) исходные данные по x , при этом сохранив значения соответствующих величин y по отношению к x .
2. Определить частоты переменной x (f_x).
3. Подсчитать среднее по переменной y для соответствующей частоты ($\bar{y}_x$);
4. Расположить по порядку (от меньшей к большей) исходные данные по y , при этом сохранив значения соответствующих величин x по отношению к y ;
5. Определить частоты переменной y (f_y);
6. Подсчитать средние по переменной x для соответствующей частоты ($\bar{x}_y$);
7. Вычислить средние значения $\bar{x}$ и $\bar{y}$;
8. Вычислить показатели корреляционного отношения h_{yx} и h_{xy}
9. Определить значимость полученных показателей с помощью критерия Стьюдента.

Задание на самостоятельную работу

Задача 1.

На основании данных ФСТЭК РФ (<https://bdu.fstec.ru/>) исследовать распределение уязвимостей по типам ошибок и ПО:

Требуется:

- 1) при уровне значимости $\alpha = 0,05$ выяснить, как зависит распределение уязвимостей от типов ошибок, ПО и календарных месяцев анализируемого периода (таблица 1), оценить степень этой зависимости;
- 2) при уровне значимости $\alpha = 0,05$ определить, что оказывает более значимое влияние на распределение уязвимостей:
 - а) типы ошибок или календарные месяцы анализируемого периода (таблица 1);
 - б) типы ПО или календарные месяцы анализируемого периода (таблица 1).
- 3) при уровне значимости $\alpha = 0,05$ выяснить влияние:
 - а) типов ошибок и календарных месяцев на распределение уязвимостей (таблица 2);
 - б) типов ПО и календарных месяцев на распределение уязвимостей (таблица 2).

Таблица 1

Вариант	Период
1	1 полугодие 2023 года
2	2 полугодие 2023 года
3	1 полугодие 2024 года
4	2 полугодие 2024 года
5	1 полугодие 2025 года

Таблица 2

Вариант	Период
1	1 полугодие 2021, 2022, 2023 годов
2	2 полугодие 2021, 2022, 2023 годов
3	1 полугодие 2022, 2023, 2024 годов
4	2 полугодие 2022, 2023, 2024 годов
5	1 полугодие 2023, 2024, 2025 года

Задача 2.

На основании данных ФСТЭК РФ (<https://bdu.fstec.ru/>) исследовать распределение уязвимостей по типам ошибок за период:

Вариант	Период
1	1 полугодие 2023 года
2	2 полугодие 2023 года
3	1 полугодие 2024 года
4	2 полугодие 2024 года
5	1 полугодие 2025 года

Требуется:

- 1) определить корреляцию уязвимостей по типам ошибок, их значимость и доверительный интервал при уровне значимости $\alpha = 0,05$;
- 2) группы (пары) для которых при возникновении одного типа ошибки из пары вероятность появления ошибки второго типа имеет высокую вероятность (характеристика силы (тесноты) связи – очень сильная);
- 3) группы, для которых при выявлении уязвимости по одному из типов ошибок с высокой вероятностью будут выявлены уязвимости всех типов ошибок из одной группы;
- 4) группы, для которых появление уязвимости, базирующейся на основном типе ошибки с высокой вероятностью, побуждает появление уязвимостей остальных типов ошибок в составе группы, а появление других элементов из группы может служить основанием для появления только основного типа ошибки.

Задача 3.

На основании данных ФСТЭК РФ (<https://bdu.fstec.ru/>) исследовать связаны ли между собой количество уязвимостей в ПО различных производителей, количество уязвимостей ПО различных производителей, связанных с инцидентами информационной безопасности, и количество критических уязвимостей в ПО различных производителей за период:

Вариант	Период
1	1 полугодие 2023 года
2	2 полугодие 2023 года
3	1 полугодие 2024 года
4	2 полугодие 2024 года
5	1 полугодие 2025 года

Значимость показателей корреляции определять при уровне значимости $\alpha = 0,05$.

Спасибо за внимание!

ITMO *re than a*
UNIVERSITY

Федоров Алексей Владимирович
avfedorov@itmo.ru