



Статистические методы в инженерных исследованиях

Лабораторная работа
Кластерный анализ

Кластерный анализ — метод классификационного анализа

Кластерный анализ — метод многомерной статистики, направленный на разбиение исследуемого множества объектов на группы (кластеры) таким образом, чтобы объекты внутри одного кластера были максимально схожи между собой, а объекты из разных кластеров — максимально различны.

Задачи кластерного анализа:

- 1) проведение классификации объектов с учетом признаков, отражающих сущность, природу объектов (углубление знаний о совокупности классифицируемых объектов).
- 2) проверка выдвигаемых предположений о наличии некоторой структуры в изучаемой совокупности объектов, (поиск существующей структуры).
- 3) построение новых классификаций для слабоизученных явлений, когда необходимо установить наличие связей внутри совокупности и попытаться привнести в нее структуру.

Основные принципы кластерного анализа:

- 1) компактности — объекты, принадлежащие одному кластеру, должны образовывать компактную группу в многомерном пространстве признаков;
- 2) делимости — различные кластеры должны находиться на существенном расстоянии друг от друга;
- 3) внутренней однородности — объекты одного кластера должны быть максимально схожи по значимым характеристикам;
- 4) внешней изолированности — объекты из разных кластеров должны существенно отличаться.

В отличие от методов классификации, кластеризация относится к методам обучения без учителя, где исследователь не знает заранее, на какие группы следует разделить данные.

Элемент кластерного анализа	Функция	Значение для аналитика
Объекты	Сущности, подлежащие группировке	-
Признаки	Характеристики объектов	Переменные для измерения сходства/различия
Метрика сходства	Способ измерения близости объектов	Определяет критерий формирования кластеров
Алгоритм кластеризации	Процедура формирования кластеров	Подбирается в зависимости от характера данных
Валидация	Оценка качества кластеризации	Определяет надежность полученных результатов

Решением задачи кластерного анализа являются разбиения, удовлетворяющие некоторому критерию оптимальности (функционал, выражающий уровни желательности различных разбиений и группировок, или целевая функция.

В качестве целевой функции может быть взята внутригрупповая сумма квадратов отклонений:

$$W = \sum_{j=1}^n (x_j - \bar{x})^2 = \sum_{j=1}^n x_j^2 - \frac{1}{n} (\sum_{j=1}^n x_j)^2$$

Этапы проведения кластерного анализа:

1. Формулировка проблемы (задачи).
2. Выбор способа измерения расстояния (определение меры сходства объектов).
3. Выбор метода кластеризации.
4. Принятие решения о количестве кластеров.
5. Интерпретация и профилирование кластеров.
6. Оценка достоверности кластеризации.

Примеры **формулировки проблемы (задачи)**.

1. Разработать модель защиты информации для анализа конструктивной безопасности архитектуры распределенного реестра с учетом политики разграничения доступа.
2. Провести кластеризацию данных информационных процессов автоматизированных систем управления, подвергающихся воздействию кибератак.
3. Обеспечить снижение размерности пространства признаков угроз в системах обеспечения информационной безопасности.
4. Разработать алгоритмы кластеризации данных в анализе журналов событий информационной безопасности.

Способы измерения расстояния (меры сходства объектов)

Выбор меры сходства объектов зависит от типа переменной и шкалы, к которой она относится.

Для каждого типа данных существует несколько способов измерения расстояния или определения меры сходства объектов.

Для определения расстояния могут использоваться различные метрики. Пусть в качестве объектов выступают точки в пространстве размерности n , которые обозначим x с координатами $\{x_1, x_2, \dots, x_n\}$ и y с координатами $\{y_1, y_2, \dots, y_n\}$.

1. **Евклидово расстояние.** Это наиболее общий вид метрики. Евклидово расстояние является геометрическим расстоянием в многомерном пространстве и вычисляется по формуле:

$$(x; y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

2. **Квадрат евклидова расстояния.** Иногда возникает потребность возвести в квадрат обычное евклидово расстояние, чтобы придать большие веса более отдаленным друг от друга объектам. Это расстояние вычисляется по формуле: $(x; y) = \sum_{i=1}^n (x_i - y_i)^2$

3. **Расстояние городских кварталов (манхэттенское расстояние):** $(x; y) = \sum_{i=1}^n |x_i - y_i|$

4. **Расстояние Чебышева:** $(x; y) = \max_{i=1, \dots, n} |x_i - y_i|$

5. **Степенное расстояние (Минковского):** $(x; y) = \left[\sum_{i=1}^n (x_i - y_i)^k \right]^{\frac{1}{k}}$

6. **Процент несогласия:** $(x; y) = \frac{\text{количество } (x_i \neq y_i)}{n}$

Методы кластеризации

1. **Центроидные методы**, основанные на представлении кластеров через их центральные точки.
2. **Иерархические методы**. Создают древовидную структуру (дендрограмму), отображающую взаимосвязь между кластерами.
3. **Плотностные методы**. Определяют кластеры как области с высокой плотностью объектов.
4. **Вероятностные методы**. Моделируют данные как смесь вероятностных распределений.
5. **Спектральные методы**. Используют собственные значения матрицы сходства для снижения размерности перед кластеризацией.

Принятие решения о количестве кластеров

1. При определении количества кластеров руководствуются теоретическими и практическими соображениями. Например, если цель кластеризации — выявление критичности угроз, то необходимо получить конкретное число кластеров.
2. В иерархической кластеризации в качестве критерия можно использовать расстояния, при которых объединяют кластеры.
3. В неиерархической кластеризации чертят график зависимости отношения суммарной внутригрупповой дисперсии к межгрупповой дисперсии от числа кластеров.
4. Относительные размеры кластеров должны быть достаточно выразительными.

Интерпретация и профилирование кластеров

Интерпретация и профилирование кластеров включает проверку кластерных центроидов.

Центроиды представляют средние значения объектов, содержащиеся в кластере по каждой из переменных. Они позволяют описывать каждый кластер, если присвоить ему номер или метку.

Процедуры обеспечивающие адекватную проверку качества кластерного анализа.

1. Выполняйте кластерный анализ на основании одних и тех же данных, но с использованием различных способов измерения расстояния. Сравните результаты, полученные на основе разных мер расстояния, чтобы определить, насколько совпадают полученные результаты.
2. Используйте разные методы кластерного анализа и сравните полученные результаты.
3. Разбейте данные на две равные части случайным образом. Выполните кластерный анализ отдельно для каждой половины. Сравните кластерные центроиды двух подвыборок.
4. Случайным образом удалите некоторые переменные. Выполните кластерный анализ по сокращенному набору переменных. Сравните результаты с полученными на основе полного набора переменных.
5. В неиерархической кластеризации решение может зависеть от порядка случаев в наборе данных. Выполните анализ несколько раз, меняя порядок случаев, до получения стабильного решения.

Методы оценки качества кластеризации

Метод оценки качества кластеризации — инструментарий для количественной оценки результатов кластеризации.

Принято выделять две группы методов оценки качества кластеризации:

Внешние меры основаны на сравнении результата кластеризации с априори известным разделением на классы. Данные меры используют дополнительные знания о кластеризуемом множестве: распределение по кластерам, количество кластеров и т.д.:

- ☐ Индекс Rand;
- ☐ Индекс Жаккара
- ☐ Индекс Фоулкса – Мэллова и др.

Внутренние меры отображают качество кластеризации только по информации в данных. Данные меры оценивают качество структуры кластеров опираясь только непосредственно на нее, не используя внешней информации:

- ☐ Отделимость кластеров;
- ☐ Индекс Данна;
- ☐ Индекс S_{Dbw} (Основан на вычислении Евклидовой нормы);
- ☐ Силуэт;
- ☐ Индекс Дэвиса-Болдуина и т.д.

Спасибо за внимание!

ITMO *re than a*
UNIVERSITY

Федоров Алексей Владимирович
avfedorov@itmo.ru