



Статистические методы в инженерных исследованиях

Структура дисциплины

«Планирование эксперимента, методы анализа и обработка данных»

1. Введение в планирование и обработку результатов эксперимента.
 - 1.1 Эксперимент как предмет исследования.
 - 1.2 Основные положения теории планирования эксперимента.
2. Первичная обработка экспериментальных данных.
 - 2.1 Параметры эмпирических распределений.
 - 2.2 Статистические гипотезы. Определение грубых погрешностей.
 - 2.3 Сравнение двух рядов наблюдений.
 - 2.4 Критерии согласия. Преобразование распределения к нормальному.
 - 2.5 Оценка погрешностей результатов наблюдений.
3. Обработка результатов пассивного эксперимента.
 - 3.1 Виды связей между рядами наблюдений.
 - 3.2 Определение коэффициентов уравнения регрессии.
 - 3.3 Характеристики связей между случайными величинами.
 - 3.4 Основные положения регрессионного анализа.
 - 3.5 Линейная множественная регрессия. Нелинейная регрессия.
4. Методы планирования эксперимента.
 - 4.1 Планирование первого порядка.
 - 4.2 Планирование второго порядка.
 - 4.3 Планирование экстремальных экспериментов.
 - 4.4 Современные проблемы теории планирования и обработки результатов эксперимента.





Раздел 3. Обработка результатов пассивного эксперимента.

Учебные вопросы:

1. Виды связей между рядами наблюдений.
2. Определение коэффициентов уравнения регрессии.
3. Характеристики связей между случайными величинами.
4. Основные положения регрессионного анализа.

Вопрос 1. Виды связей между рядами наблюдений

$$\hat{y} = f(X) \quad (1)$$



Факторы – независимые параметры $X = (x_1, \dots, x_k)$.

Отклики – зависимые переменные y .

Факторное пространство – координатное пространство с координатами $x_1, x_2, \dots, x_i, \dots, x_k$.

Однофакторный эксперимент – эксперимент по определению функции вида:

$$\hat{y} = f(x), \quad (2)$$

где x – скалярная величина.

Многофакторный эксперимент – эксперимент по определению функции вида:

$$\hat{y} = f(X), \quad (3)$$

где $X = (x_1, x_2, \dots, x_i, \dots, x_k)$.

Функциональные связи (зависимости) – связи, при которых при изменении величины X другая величина y изменяется так, что каждому значению x_i соответствует однозначное y_i (рисунок 1а).

Стохастичность связи $\Rightarrow$ одна случайная переменная y реагирует на изменение другой X изменением своего закона распределения (рисунок 1б – тесная связь, рисунок 1в – слабая связь).

Теснота связи – степень близости стохастической зависимости к функциональной.




Рисунок 1 – Виды связей

Анализ стохастических связей приводит к различным постановкам задач статистического исследования зависимостей, которые упрощенно можно классифицировать следующим образом:

- ✓ *Задачи корреляционного анализа* – исследуется наличие взаимосвязей между отдельными группами переменных.
- ✓ *Задачи регрессионного анализа* – устанавливаются аналитические зависимости между y и одной или несколькими переменными x .
- ✓ *Задачи дисперсионного анализа* – переменные x имеют качественный характер, исследуется и устанавливается их влияние на y .

$$\hat{y} = b_0 + \sum_{j=1}^k b_j x_j, \quad (4)$$

где $b_0, \dots, b_j, \dots, b_k$ - коэффициенты уравнения.

Частные средние для каждого интервала:

$$\bar{y}_j = \frac{\sum_{i=1}^{n_j} y_{ji}}{n_j}. \quad (5)$$

где n_j - число точек в интервале Δx_j .




Рисунок 2 – Построение линии регрессии

Вопрос 2. Определение коэффициентов уравнения регрессии

Имеем вид уравнения регрессии, требуется определить численные значения коэффициентов

$$b_0 = \{b_0, \dots, b_j, \dots, b_k\} \quad (6)$$

Основные подходы к нахождению коэффициентов b_j :

✓ Интерполирование. $\hat{y} = (X, b)$.

$$f(x_i, b_0, \dots, b_j, \dots, b_k) = y_i, 1 \leq i \leq n \quad (7)$$




Рисунок 3 – Аппроксимация функции
с большим (1) и небольшим (2) числом коэффициентов

Интерполирование

1. Метод избранных точек. На основании анализа данных выдвигают гипотезу о виде (форме) зависимости $f(X)$. Предположим, что она линейная, т.е. статистическая связь – это линейная одномерная регрессия:

$$\hat{y} = b_0 + b_1 x \quad (8)$$

Выбирают две наиболее характерные точки, через которые строится линия регрессии:





Рисунок 4 – Метод избранных точек

Интерполирование

2. Метод медианных центров. Обведенное контуром поле точек делят на несколько частей, число которых равно числу определяемых коэффициентов уравнения регрессии. В каждой области находят медианный центр => через медианные центры проводят плавную кривую => определяют коэффициенты регрессии:



$$\left\{ \begin{array}{l} \bar{y}_I = b_0 + b_I \bar{x}_I \\ \bar{y}_{II} = b_0 + b_I \bar{x}_{II} \end{array} \right. \quad (9)$$

Рисунок 5 – Метод медианных точек

$$\hat{f}(x_i, b_0, \dots, b_j, \dots, b_k) = y_i, 1 \leq i \leq n \quad (7)$$

✓ Метод наименьших квадратов.



$$\Phi(b_0, b_1, \dots, b_j, \dots, b_k) = \sum_{i=1}^n [f(x_i, b_0, b_1, \dots, b_j, \dots, b_k) - y_i]^2 \rightarrow \min_{b_j}, \quad (10)$$

где n – число экспериментальных точек в рассматриваемом интервале изменения аргумента x .

Необходимым условием минимума функции $\Phi(b_0, b_1, \dots, b_j, \dots, b_k)$ является выполнение равенства:

$$\partial \Phi / \partial b_j = 0, \quad 0 \leq j \leq k \quad (11)$$

или

$$\sum_{i=1}^n [f(x_i, b_0, b_1, \dots, b_j, \dots, b_k) - y_i] \frac{\partial f(x_i)}{\partial b_j} = 0, \quad 0 \leq j \leq k. \quad (12)$$

$$\sum_{i=1}^n [f(x_i, b_0, b_1, \dots, b_j, \dots, b_k) \frac{\partial f(x_i)}{\partial b_j} - y_i \frac{\partial f(x_i)}{\partial b_j}] = 0. \quad (13) \text{ – система нормальных уравнений}$$

Вопрос 3.

Характеристики связей между случайными величинами.

Остаточная дисперсия $S_{y \text{ ост}}^2$ характеризует разброс экспериментально наблюдаемых точек относительно линии регрессии и представляет собой показатель ошибки предсказания параметра y по уравнению регрессии (рисунок 6).

$$S_{y \text{ ост}}^2 = \frac{1}{n-l} \sum_{i=1}^n [y_i - \hat{y}_i]^2 = \frac{1}{n-l-k} \sum_{i=1}^n [y_i - f(x_i, b_0, b_1, \dots, b_k)]^2, \quad (14)$$

где $l=k+1$ – число коэффициентов уравнения модели.

Общая дисперсия (дисперсия выходного параметра) S_y^2 характеризует разброс экспериментально наблюдаемых точек относительно среднего значения $\bar{y}$, т.е. линии C (рисунок 6)

$$S_y^2 = \frac{1}{n-1} \sum_{i=1}^n [y_i - \bar{y}]^2, \quad (15)$$

$$\text{где } \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i.$$

Средний квадрат отклонения линии регрессии от среднего значения линии $\bar{y} = C$.



$$S_y^{*2} = \frac{1}{n-1} \sum_{i=1}^n [\hat{y}_i - \bar{y}]^2 = \frac{1}{n-1} \sum_{i=1}^n [f(x_i, b_0, b_1, \dots, b_k) - \bar{y}]^2. \quad (16)$$




Рисунок 6 – Определение дисперсий

Общая дисперсия: $S_y^2 = S_{y_{\text{ост}}}^2 + S_y^{*2}. \quad (17)$

$$\rho_{xy}^* = \sqrt{\frac{S_y^2 - S_{y\text{ост}}^2}{S_y^2}} = \sqrt{1 - \frac{S_{y\text{ост}}^2}{S_y^2}} = \sqrt{\frac{S_y^{*2}}{S_y^2}} = \frac{S_y^*}{S_y}. \quad (18)$$

Анализ свойств показателя ρ_{xy}^* :

1. Связь функциональная $\Rightarrow$ корреляционное отношение равно 1, остаточная дисперсия равна $S_{y\text{ост}}^2 = 0, S_y^{*2} = S_y^2$, (рисунок 7а).
2. Корреляционное отношение равно 0 $\Rightarrow$ отсутствие тесной связи между x и y : $S_y^2 = S_{y\text{ост}}^2$. (рисунок 7б).




Рисунок 7 – Значения выборочного корреляционного отношения ρ_{xy} :
а) функциональная связь; б) отсутствие связи

Выборочное корреляционное отношение

3. Чем ближе расположены экспериментальные данные к линии регрессии, тем теснее связь, тем меньше остаточная дисперсия и тем больше корреляционное отношение.

Коэффициент детерминации – квадрат корреляционного отношения:

$$R^2 = \rho_{xy}^{*2} = 1 - \frac{S_{y\text{ост}}^2}{S_y^2} \quad (19)$$

Вопрос 4. Основные положения регрессионного анализа

При проведении регрессионного анализа примем следующие допущения:



- ✓ входной параметр x измеряется с пренебрежимо малой ошибкой. Появление ошибки в определении y объясняется наличием в процессе не выявленных переменных и случайных воздействий, не вошедших в уравнение регрессии;
- ✓ результаты наблюдений $y_1, y_2, \dots, y_i, \dots, y_n$ над выходной величиной представляют собой независимые нормально распределенные случайные величины;
- ✓ При проведении эксперимента с объемом выборки n при условии, что каждый опыт повторен m^* раз, выборочные дисперсии $S_1^2, \dots, S_i^2, \dots, S_n^2$ должны быть однородны.

Адекватная регрессионная модель – модель, у которой предсказанные значения $\hat{y}$ согласуются с результатами наблюдений.



Нулевая гипотеза: «Уравнение регрессии адекватно».

Альтернативная гипотеза: «Уравнение регрессии неадекватно».

Используем F-критерий Фишера (сравнивая S_y^2 и $S_{y\text{ост}}^2$).



$$S_y^2 = \frac{\sum_{i=1}^n [y_i - \bar{y}]^2}{n-1};$$
$$S_{y\text{ост}}^2 = \frac{\sum_{i=1}^n [y_i - \hat{y}_i]^2}{n-l},$$

Определяем экспериментальное значение F-критерия:

$$F = S_y^2 / S_{y\text{ост}}^2 \quad (20)$$

$l=k+1$

(для линейной зависимости:
 $k=1, l=2$.)

Если $F > F_{\alpha; m_1; m_2} \Rightarrow$ уравнение адекватно.

Альтернативный случай

1. Определяется $\bar{y}_i = \sum_{j=1}^{m^*} y_{ij} / m^*$ - среднее из серии параллельных опытов при $x = x_i$,

где y_{ij} - значение параметра y при $x = x_i$ в j -м случае.

2. Рассчитываются значения параметра $\hat{y}_i$ по уравнению регрессии при $x = x_i$.

3. Рассчитывается дисперсия адекватности:

$$S_{ad}^2 = \frac{\sum_{i=1}^n [\bar{y}_i - \hat{y}_i]^2}{n - l}, \quad (21)$$

где n – число значений x_i , l – число членов аппроксимирующего полинома (коэффициентов b_i) – для линейной зависимости $l=2$.

4. Определяется выборочная дисперсия Y при $x = x_i$:

$$S_i^2 = \frac{\sum_{j=1}^{m^*} [y_{ij} - \bar{y}_i]^2}{m^* - 1}; \quad (22)$$

5. Определяется дисперсия воспроизводимости

$$S_{\text{восп}}^2 = \sum_{i=1}^n S_i^2 / n. \quad (23)$$

Число степеней свободы этой дисперсии равно $m=n(m^*-1)$.

6. Определяется экспериментальное число критерия Фишера

$$F = S_{\text{ад}}^2 / S_{\text{восп}}^2 \quad (24)$$

7. Определяется теоретическое значение этого же критерия $F_{\alpha;m1;m2}$, где $m1=n-1$; $m2=n(m^*=1)$.

8. Если $F \leq F_{\alpha;m1;m2}$, то уравнение регрессии адекватно, в противном случае – нет.

Имеется распределение со средним значением $\hat{y}_i = b_0 + b_1 x_i$ и дисперсией $S_{yi}^2 = S_{\text{восп.}}^2$

Допущение $\Rightarrow S_{yi}^2 = \text{const}$




Рисунок 8 – Парная корреляция в случае
двумерного нормального распределения
параметров

По закону накопления ошибок:

$$S_{b_i} = \sqrt{\sum_{j=1}^n \left(\frac{\partial b_j}{\partial y_i} \right)^2 S_j^2}. \quad (25)$$

При условии, что $S_{y1}^2 = S_{y2}^2 = \dots = S_{yi}^2 = \dots S_{yn}^2 = S_{\text{восп}}^2$, получим:

$$S_{b_0} = \frac{\sqrt{S_{\text{восп}}^2 \sum_{i=1}^n x_i^2}}{\sqrt{n \sum_{i=1}^n x_i^2 - \left(\sum_{i=1}^n x_i \right)^2}}; \quad (26)$$

$$S_{b_1} = \frac{\sqrt{S_{\text{восп}}^2 \cdot n}}{\sqrt{n \sum_{i=1}^n x_i^2 - \left(\sum_{i=1}^n x_i \right)^2}}. \quad (27)$$

Доверительный интервал для коэффициентов уравнения регрессии: $\Delta b_i = t_{\alpha;n-1} \cdot S_{b_i} \quad (28)$



Если $|b_i| > |\Delta b_i|$, то коэффициент регрессии b_i значим, в противном случае – нет.

Пример

Проведено измерение теплоемкости оксида углерода (CO) от температуры

№ опыта	Температура, град. С	Теплоемкость, кДж/(м ³ *К)
1	0	1,298
2	100	1,302
3	200	1,306
4	300	1,315
5	400	1,327
6	500	1,344
7	600	1,357
8	700	1,373
9	800	1,384
10	900	1,398

№ опыта	Температура, град. С	Теплоемкость, кДж/(м ³ *К)
11	1000	1,411
12	1100	1,424
13	1200	1,436



1. Получим уравнение регрессии. (построим в Excel точечную диаграмму и добавим к ней линию тренда линейного вида).




Рисунок 9 – Точечная диаграмма в Excel

Получен коэффициент детерминации R^2 : $y=0,0001*x + 1,2854$
 $R^2 = 0,9877$

2. Построим статистику для линейного уравнения регрессии («ЛИНЕЙН»).

Получены следующие данные:

$$b_0 = 1,28543956$$

$$b_1 = 0,000123626$$

$$S_{b0} = 0,00294447$$

$$S_{b1} = 0,000004164$$

$$R^2 = 0,987673831$$

$$\Delta y = 0,00561769$$

$$F = 881,4102564$$

$$m = 11$$

$$S_{y_{\text{ост}}}^2 = 06000347143$$

$$S_y^{2*} = 0,027815934$$

Для расчета коэффициента корреляции используем следующую формулу:

$$\rho_{xy}^{2*} = \frac{S_y^{*2}}{S_y^{*2} + S_{y_{\text{ост}}}^2} \quad (29)$$

$$R^2 = \frac{S_y^{2*}}{(S_y^{2*} + S_{y_{\text{ост}}}^2)} = \frac{0,027815934}{0,027815934 + 0,000347143} = 0,987673831.$$

3. Рассчитываем доверительный интервал для коэффициентов уравнения регрессии (СТЬЮДЕНТ.ОБР.2X(0,05;11):

$$t_{0,005;11} = 2,20098516$$

Тогда

$$\Delta b_0 = 2,20098516 * 0,00294447 = 0,006480734$$

$$\Delta b_1 = 2,20098516 * 0,00004164 = 0,000009165$$



Коэффициенты уравнения регрессии значимы

4. Для оценки адекватности модели применяем F-критерий Фишера (F.ОБР.ПХ(0,05;12;11)).

$$F_{0,05;12;11} = 2,787569326.$$



Уравнение адекватное

5. Проверка в пакете Statistica.

4* - Итоги регрессии для зависимой переменной: Var2 (Таблица данных13)

Итоги регрессии для зависимой переменной: Var2 (Таблица данных13)
 $R = ,99381781$ $R^2 = ,98767383$ Скорректир. $R^2 = ,98655327$
 $F(1,11) = 881,41$ $p < ,00000$ Станд. ошибка оценки: ,00562

N=13	БЕТА	Стд. Ош. БЕТА	B	Стд. Ош. B	t(11)	p-уров.
Св.член			1,285440	0,002944	436,5606	0,000000
Var1	0,993818	0,033475	0,000124	0,000004	29,6886	0,000000

Рисунок 10 – Результаты расчета линии регрессии в пакете Statistica

Продукты линейки *STATISTICA* – это мощнейшие инструменты для анализа данных, визуализации, прогнозирования, нейросетевых вычислений, data mining, контроля качества.



Преимущества использования программных пакетов *STATISTICA*:

- ✓ Интерфейс *STATISTICA* является интуитивно понятным, легко настраивается в соответствии с пользовательскими задачами и аналогичен интерфейсу стандартных Windows приложений, поэтому легко осваивается пользователем.
- ✓ Анализ данных проводится интерактивно, в режиме последовательно открывающихся диалоговых окон. Любое окно анализа сконструировано таким образом, что на первой вкладке содержатся только самые необходимые кнопки, а на последующих вкладках – углубленные методы и специальные опции.

Таким образом, внимание новичка не отвлекают дополнительные настройки и параметры, а продвинутый пользователь сможет всегда настроить анализ по своему усмотрению/